Хувийн туслах AI агентын архитектур

Week 04 даалгавар

23B1NUM1041 П.Дөлгөөн

1 arc42 Танилцуулга ба зорилго

Хувийн туслах AI агент нь дуут хүсэлтийг ойлгож, Google Calendar-д уулзалт үүсгэх, Gmail-д ноорог бэлтгэх ба баталгаажуулсны дараа илгээх, Contacts-оос харилцагч хайх систем юм. Архитектурын гол шийдэл нь AI-ийн санал болгосон үйлдлийг OAuth эрх болон хэрэглэгчийн баталгаажуулалтаар шалгадаг тусдаа серверийн хяналтаар дамжуулах явдал юм.

1 1 Шаардлагын суурь

Week 3 SRS v1.0-ийн FR-01–FR-15, NFR-01–NFR-05-ыг үндсэн baseline болгосон. Week 2-т Gmail-ийн draft байсан бол Week 3-ын FR-10, FR-11-д хяналттай илгээх нэмэгдсэн. Иймээс W2 ба W3-ын ижил дугаартай шаардлагыг адил гэж үзээгүй. Энэ FR, NFR нь W3-ын ID юм.

Чанарын зорилго	Хэмжигдэх шалгуур ба эзэн
Аюулгүй үйлдэл	NFR-03: 20 бичих үйлдлийн 100% OAuth ба ил тод баталгаажуулалтын бүртгэлтэй. B22.
Гүйцэтгэл	NFR-01: 30 аудиод STT p95 ≤ 2 сек. NFR-02: 50 командад гаднын API-г хассан дотоод хариу p95 ≤ 500 мс. B3, B21.
Давхардалгүй байдал	NFR-04: 30 давталтад Calendar event 0 давхардалтай. B23, B25.
Хүртээмж	NFR-05: гол удирдлага бүрт ≤ 5 Tab, фокус харагдана. B1.

1 2 Хамрах хүрээ

Хамрах нь: микрофон, STT, зорилго таних, OAuth, Calendar үүсгэх, Gmail draft бичих ба илгээх, People API хайлт, үр дүн ба алдааны тайлбар. Хасах нь: бүрэн автономит шийдвэр, бүрэн Gmail client, Google-ээс бусад бизнес интеграци (integration). Calendar засах/устгах, олон хэрэглэгчийн эрхийн удирдлага, олон хэл, урт хугацааны memory нь W2-ын дагуу хойшлогдоно.

Шийдвэрүүд нь W4-ийн санал болгож буй загвар. Архитектурын mapping нь хэрэгжүүлэлт болон туршилт амжилттай болсон гэсэн нотолгоо биш.

3 arc42 Хамрах хүрээ ба системийн орчин

3 1 Оролцогч ба persona холбоос

ID ба дүр	W1 эх сурвалж ба хүндрэл	Хүлээлт
P1 Ану API интеграцийн хөгжүүлэгч	W1 2, х. 1–2. PP1 OAuth/token төвөгтэй; PP2 scope ойлгомжгүй; PP3 олон API-ийн алдааг ялгахад хэцүү.	Тест хүсэлт, API гэрээ, scope болон засах алхам.
P2 Эцсийн хэрэглэгч	W1 4, х. 3-ын “уулзалт товло” хэрэгцээгээр W4-т өргөжүүлсэн дүр. Тусдаа W1 persona card биш.	Дуут хүсэлт, танигдсан текст, хянах/цуцлах, тодорхой үр дүн.
P3 Засвар үйлчилгээний хөгжүүлэгч	W1 4-ийн Support/Engineering үүрэг ба P1-PP3-аас W4-т өргөжүүлсэн дүр. Тусдаа W1 persona card биш.	Нууц өгөгдөлгүй оношлогоо, correlation ID, алдааны ангилал.

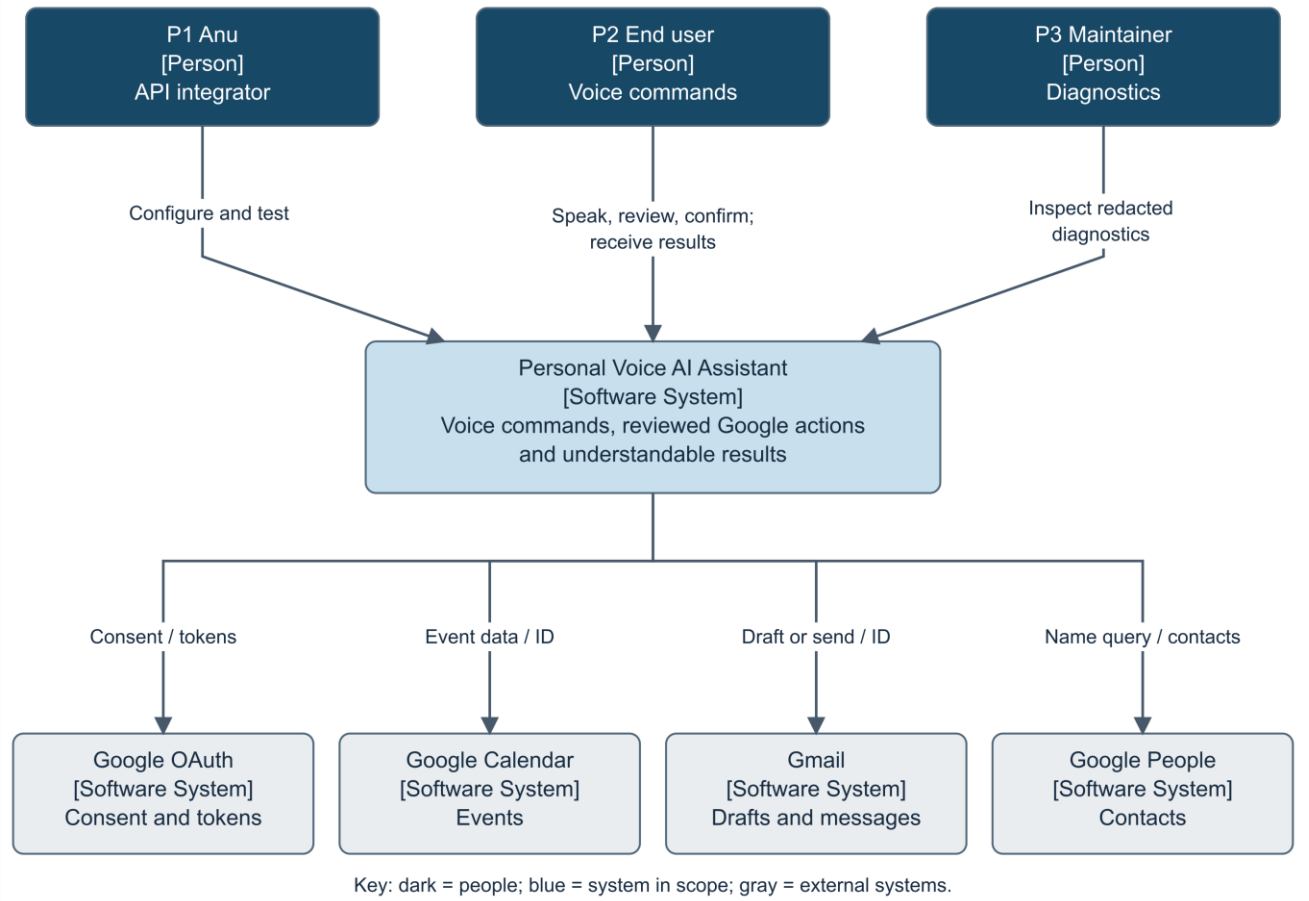
W1-д үндсэн төслийн нэг нэрлэсэн persona буюу Ану байна. Corg.ly-ийн Батаа нь өөр кейс тул энэ системийн persona болгон ашиглаагүй. P2, P3-ыг дараагийн review-ээр persona card болгон баталгаажуулна. Гурван actor зурагт орсон боловч гурвуулаа W1-ийн батлагдсан persona гэсэн шалгуур бүрэн хангагдаагүй.

3 2 Гаднын систем ба өгөгдлийн урсгал

Хөрш систем	Системээс гарах → буцаж ирэх өгөгдөл
Google OAuth	Зөвшөөрлийн хүсэлт, scope; code солилцоо → access/refresh token эсвэл татгалзалт. HTTPS, browser redirect.
Google Calendar API	Баталгаажсан гарчиг, огноо, цаг, event ID → үүссэн event/ID эсвэл алдаа. HTTPS/JSON.
Gmail API	Хэнд, гарчиг, агуулга; зөвшөөрсөн draft/send хүсэлт → draft ID, message ID эсвэл алдаа. HTTPS.
Google People API	Нэр эсвэл хайлтын текст → харилцагчийн нэр, и-мэйл, олон/хоосон тохирол. HTTPS/JSON.

Эрхийн хил: browser-д Google refresh token хадгалахгүй. API нь OAuth scope-ыг үйлдэл бүрт шалгана. P3 зөвхөн developer орчны эсвэл хязгаарласан diagnostics endpoint-оор халхалсан log уншина; энэ нь хэрэглэгчдийн олон түвшний эрхийн шинэ бүтээгдэхүүний функц биш.

3 3 C4 System Context зураг

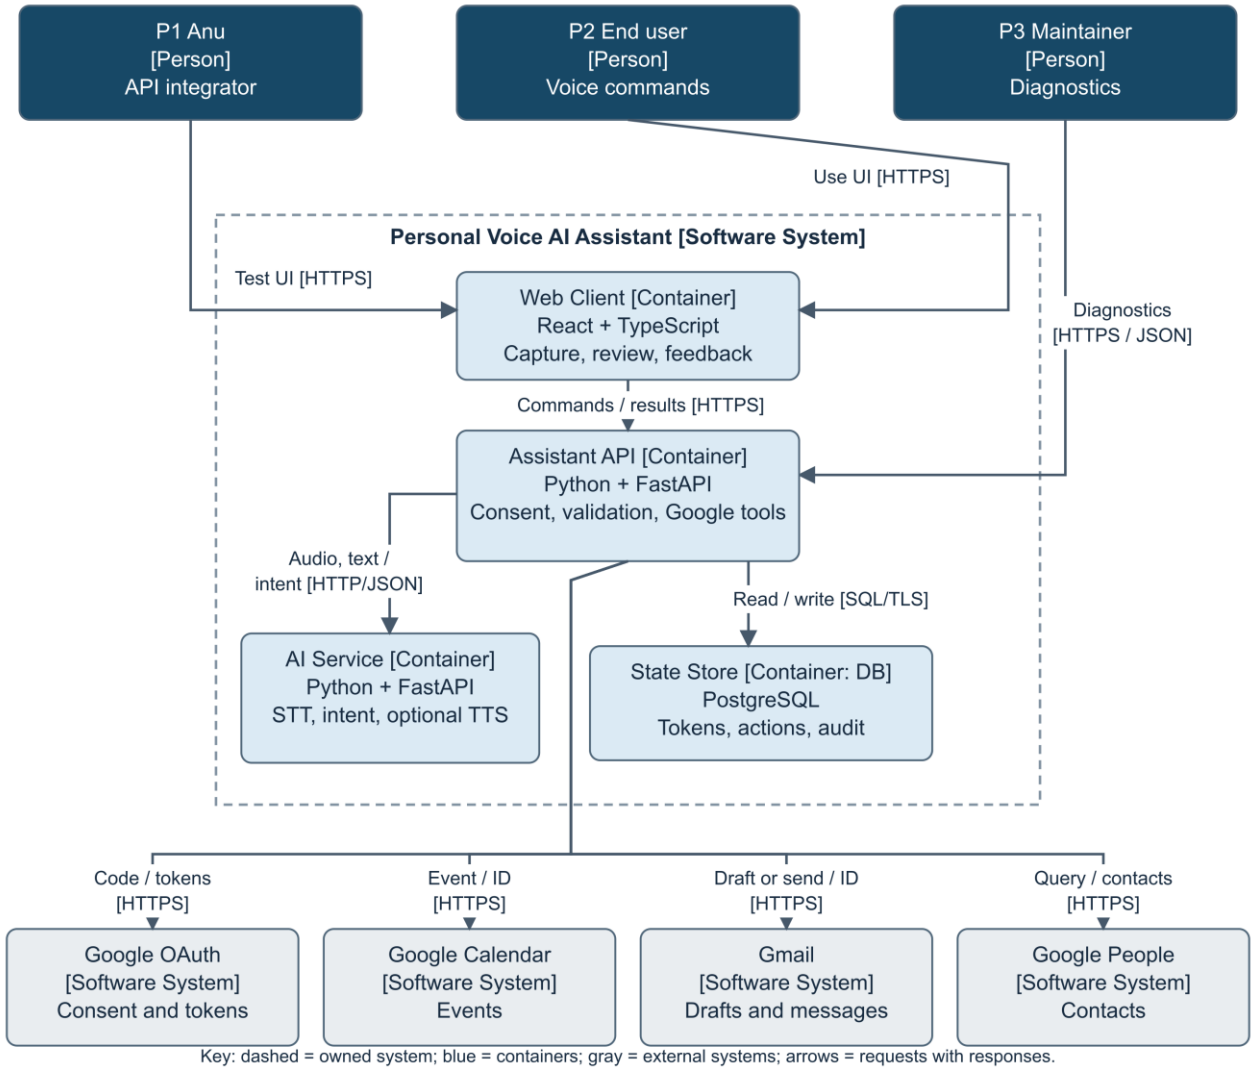


Өгөгдлийн хязгаар

Аудиог боловсруулж дуустал түр санах ойд байлгана. Google-ийн и-мэйл, харилцагчийн бүрэн хуулбарыг локал сан руу байнга синк хийхгүй. Log-д token, аудио, и-мэйлийн үндсэн агуулгыг бичихгүй; үйлдлийн төрөл, төлөв, correlation ID-гаар асуудлыг мөшгөнө. Хадгалалтын бодлогыг ADR-002-т тодорхойлсон.

5 arc42 Building Block View

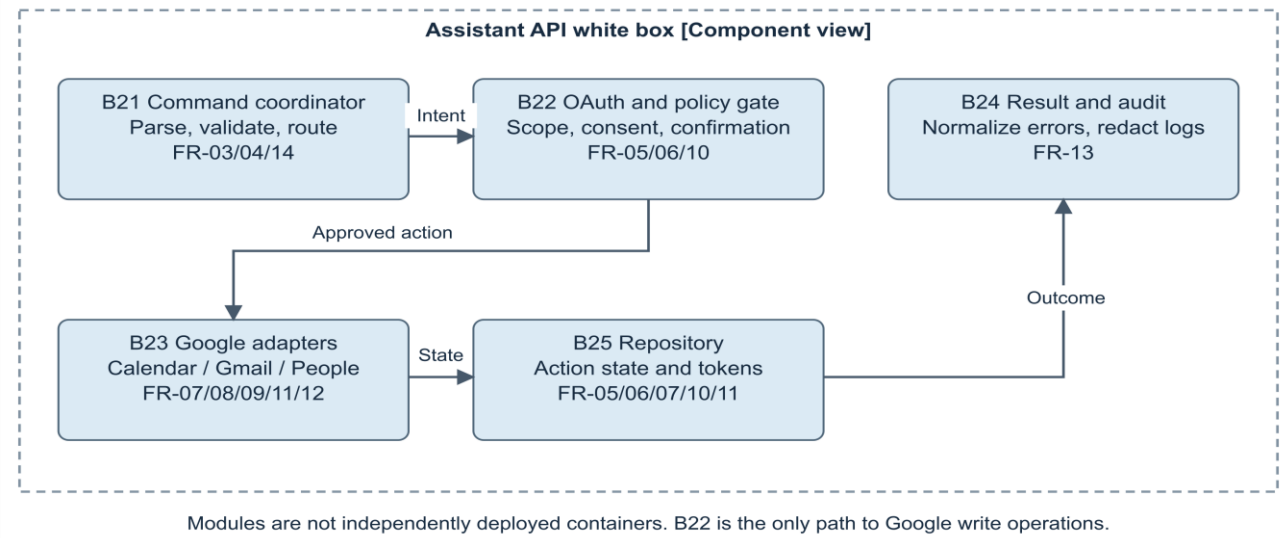
5 1 C4 Container зураг



B1 Web Client, B2 Assistant API, B3 AI Service, B4 State Store нь тусдаа ажиллуулах/байршуулах нэгжүүд. PostgreSQL нь өгөгдлийн container; B21–B25 нь B2-ын дотоод модуль тул container-ын тоонд нэмэхгүй. Технологи нь W4-ийн сонголт бөгөөд W1–W3-т хэрэгжсэн стек гэж үзэхгүй.

5 2 Блокуудын хариуцлага ба интерфейс

Блок	Хариуцлага ба интерфейс	W3 шаардлага
B1 Web Client	React + TypeScript. Микрофон, текст, review, сонголт, үр дүн. API руу HTTPS; нууц token-гүй.	FR-01–05, 08–14
B2 Assistant API	Python + FastAPI. Session, validation, policy, Google adapters; /commands, /actions/{id}/confirm.	FR-02–14
B3 AI Service	Python + FastAPI; сонгох STT/intent/TTS модель. /transcribe, /interpret, /synthesize. Google token/үйлдлийн эрхгүй.	FR-02–04, 13–14
B4 State Store	PostgreSQL. Token metadata, шифрлэсэн refresh token, action state, confirmation, audit. Зөвхөн B2 холбогдоно.	FR-05–07, 09–11, 13



B21 нь AI-ийн үр дүнг schema-гаар шалгаж, дутуу талбарыг асууна. B22 нь session, scope, action version болон confirmation-ыг шалгасны дараа B23-ыг дуудна. B23 provider-specific алдааг B24-ийн нэгдсэн хэлбэрт өгнө. B25 нь action state transition ба давхардлын түлхүүрийг хадгална.

5 3 SRS шаардлагын мөрдөлт

Доорх товчлол нь W3-ын эх шаардлагыг солихгүй. Нэг ID нэг удаа тоологдоно; блокийн жагсаалт нь хангах архитектурын хариуцлагыг заана.

ID	W3 шаардлагын товч утга	Хариуцсан блок
FR-01	Микрофон эхлүүлэх, зогсоох	B1
FR-02	Дуут командыг текстээр харуулах	B1, B2, B3
FR-03	Calendar/Gmail/Contacts/тодорхойгүй ангилал	B1, B21, B3
FR-04	Calendar талбар задлах, дутууг асуух	B1, B21, B3
FR-05	Calendar үүсгэхээс өмнөх баталгаажуулалт	B1, B22, B25
FR-06	Google үйлдлийн өмнө OAuth эрх авах	B1, B22, B25
FR-07	Баталгаажсан Calendar event үүсгэх	B23, B25
FR-08	Хүлээн авагч хайх, олон тохиролд сонгох	B1, B23
FR-09	Gmail-д ноорог үүсгэх	B1, B23, B25
FR-10	Илгээхээс өмнө хянах, засах, батлах	B1, B22, B25
FR-11	Баталгаажсан и-мэйлийг илгээх	B23, B25
FR-12	Contacts үр дүн/хоосон төлөв харуулах	B1, B23
FR-13	Амжилт, цуцлалт, алдаа; боломжтой бол TTS	B1, B24, B3
FR-14	Дахин хэлэх, засах, цуцлах	B1, B21, B3
FR-15	Сессийн товч түүх	ORPHAN — W5

Хамралт = 14 / 15 × 100 = 93.3%. Энэ нь ≥ 80% зорилтыг хангана. FR-15 (Could) нь хэрэглэгчид харагдах history API/UI эзэнгүй учир orphan. Audit log байгаа нь FR-15 хангагдсан гэсэн үг биш. W5-д B26 Session History модуль болон UI-г тодорхойлж T-FR15-тай холбоно.

NFR ба шалгах арга

NFR-01 → B3/B1, T-NFR01: 30 аудио; NFR-02 → B21/B3/B1, T-NFR02: 50 команд; NFR-03 → B22/B25, T-NFR03: 20 audit; NFR-04 → B23/B25, T-NFR04: 30 давталт; NFR-05 → B1, T-NFR05: гарын Tab шалгалт. Дотоод AI inference нь NFR-02-ын хугацаанд орно; үүнийг гаднын API мэт хасаж тооцохгүй.

Architecture ADR индекс ба ADR 001

ADR	Шийдвэр	Төлөв ба persona холбоос
001	React болон Python FastAPI стек	Proposed; P1-PP3
002	PostgreSQL ба хяналттай хадгалалт	Proposed; P1-PP1, PP3
003	Дуу ба текстгэй хяналттай интерфейс	Proposed; P1-PP2, P2
004	Magic Assistant-ийг задалсан refactoring	Proposed; P1-PP1/PP2/PP3, P3

ADR-001 рүү очих

ADR-002 рүү очих

ADR-003 рүү очих

ADR-004 рүү очих

ADR 001 Технологийн стек

Context and problem statement

Ану Python, REST API, Postman ашигладаг боловч олон API-ийн алдааны эх үүсвэрийг ялгахад хүндрэлтэй (W1 §2, P1-PP3). W3-ын FR-01–14 нь UI, AI боловсруулалт, Google интеграцийг тус тус шалгах шаардлагатай. Нэг файлд холих нь алдааны эзнийг бүдгэрүүлнэ.

Decision drivers and options

Шалгуур: Python мэдлэгтэй нийцэх, тодорхой API гэрээ, тусгаарлан тестлэх, дөрвөөс ихгүй үндсэн container. Хувилбарууд: нэг Python desktop application; React + FastAPI modular API; олон жижиг microservice. Desktop нь түгээлтэд, microservice нь хичээлийн хүрээнд ажиллагааны нэмэлт зардалтай.

Decision

React/TypeScript browser client, Python/FastAPI API болон тусдаа Python AI service сонгоно. B2 дотор OAuth, command, Google adapter модулиудтай modular бүтэц хэрэглэнэ. API хүсэлт/хариуг schema-гаар тодорхойлж OpenAPI reference, амжилт ба 401/403 төрлийн алдааны жишээ гаргана. STT/TTS model болон хэлний тохиргоог W5 benchmark-ийн дараа хувилбараар түгжинэ.

Consequences and validation

Давуу тал: Ану танил Python орчиндоо provider adapter-ыг шалгаж, correlation ID-аар аль шат алдаатайг олно. Сул тал: client/server гэрээ болон AI service deployment-ийг зэрэг арчилна. NFR-01/02 биелсэн гэж урьдчилан үзэхгүй; T-FR02/03 ба latency тестээр хэмжинэ. Model-ийн чанар хангалтгүй бол ADR-ийг шинэчилнэ.

ADR 002 Өгөгдөл хадгалалт

Context and problem statement

Анугийн OAuth token-ийн хүндрэл (P1-PP1) болон алдаа оношлох хэрэгцээ (P1-PP3) нь эрх, баталгаажуулалт, API үр дүнг нэг action ID-аар холбохыг шаарддаг. W3 NFR-03 audit нотолгоо, NFR-04 давхар Calendar event-ээс сэргийлэх шалгууртай. Зөвхөн санах ой ашиглавал restart-ын дараа аль үйлдэл баталгаажсан, гүйцэтгэсэн эсэх алдагдана.

Decision drivers and considered options

Шалгуур: transaction, unique constraint, token тусгаарлалт, сэргээх боломж, жижиг төслийн ажиллагааны зардал. Хувилбарууд: process memory; SQLite файл; PostgreSQL. Memory нь durable биш. SQLite нь local prototype-д хялбар боловч зэрэгцээ backend instance болон төвлөрсөн backup-ийн төлөвлөгөөнд PostgreSQL сонгов.

Decision

B4 PostgreSQL-д OAuth connection, action, confirmation, execution_attempt, audit_event хүснэгт хадгална. Action бүр user/session, төрөл, payload hash/version, idempotency key, төлөв, provider resource ID-тай байна. Token-ийг application түвшинд шифрлэж, түлхүүрийг DB-ээс тусдаа environment/secret store-д байрлуулна. Browser болон B3 Google token уншихгүй.

Action state: proposed → confirmed → executing → succeeded/failed/unknown. Цуцалсан эсвэл зассан payload нь хуучин confirmation-ыг хүчингүй болгоно. Unique key ба transaction нь нэг action зэрэг гүйцэтгэгдэхээс хамгаална. Гаднын API дуудлага ба DB transaction нь атом биш тул timeout-ыг шууд failed гэж үзэхгүй.

Давхардал ба хадгалалтын бодлого

Calendar retry-д тогтвортой client event ID хэрэглэж, timeout-ын дараа тухайн ID-аар шалгана; шууд дахин event үүсгэхгүй. Gmail send-ийн үр дүн тодорхойгүй бол unknown төлөвт оруулж, sent төлөвийг нягтлах хүртэл автоматаар дахин илгээхгүй. Provider-ийн retry semantics-ийг хэрэгжүүлэх үед албан ёсны API reference-ээр батална.

Санал болгосон retention: raw audio байнга хадгалахгүй; command payload-ыг дууссан үйлдлээс 24 цагийн дараа арилгах; агуулгагүй audit metadata-г 30 хоног хадгалах; хэрэглэгч connection салгахад token устгах. Эдгээр хугацаа нь W4-ийн шийдвэр бөгөөд W3-ын шинэ шаардлага болгон review хийх ёстой.

Consequences and validation

Давуу тал: баталгаажуулалт, эрх, үр дүн мөшгөгдөнө; давхардсан хүсэлтийг илрүүлнэ. Сул тал: backup, migration, key rotation, retention job шаардлагатай. T-NFR03-ын 20 audit болон T-NFR04-ын 30 давталт, restart/timeout тестээр батална. FR-15-ын history дэлгэцийг энэ шийдвэр автоматаар хэрэгжүүлэхгүй.

ADR 003 Хяналттай дуу ба текстийн интерфейс

Context and problem statement

P1-PP2 нь ямар scope ямар үйлдэл зөвшөөрдөг нь тодорхойгүйг тэмдэглэсэн. P2 нь “уулзалт товло” гэсэн хүсэлтээ энгийнээр өгөхийг хүснэ. W3 FR-05, FR-10, NFR-03 нь бичих үйлдлийн өмнө ил тод баталгаажуулалт шаардана. Дуу буруу танигдсан үед зөвхөн OAuth эрх байгаа нь тухайн агуулгыг зөвшөөрсөн гэсэн үг биш.

Decision drivers and options

Хувилбарууд: шууд автономит voice-only гүйцэтгэл; text-only интерфейс; voice input + visible text review. Эхнийх нь scope charter-тай зөрчилдөнө. Text-only нь FR-01-ийг хангахгүй. Гурав дахь хувилбар нь дуут хэрэглээ ба шалгаж засах боломжийг нэгтгэнэ.

Decision

Дууг текст болгон харуулж, танигдсан зорилго ба дутуу талбарыг ил тод үзүүлнэ. Calendar-д гарчиг, огноо, timezone, эхлэх/дуусах цаг; Gmail-д хүлээн авагчийн бодит хаяг, гарчиг, агуулгыг харуулна. Contacts олон тохиролтой бол хэрэглэгч сонгоно. Тодорхойгүй команд дээр дахин хэлэх, засах, цуцлах сонголт өгнө.

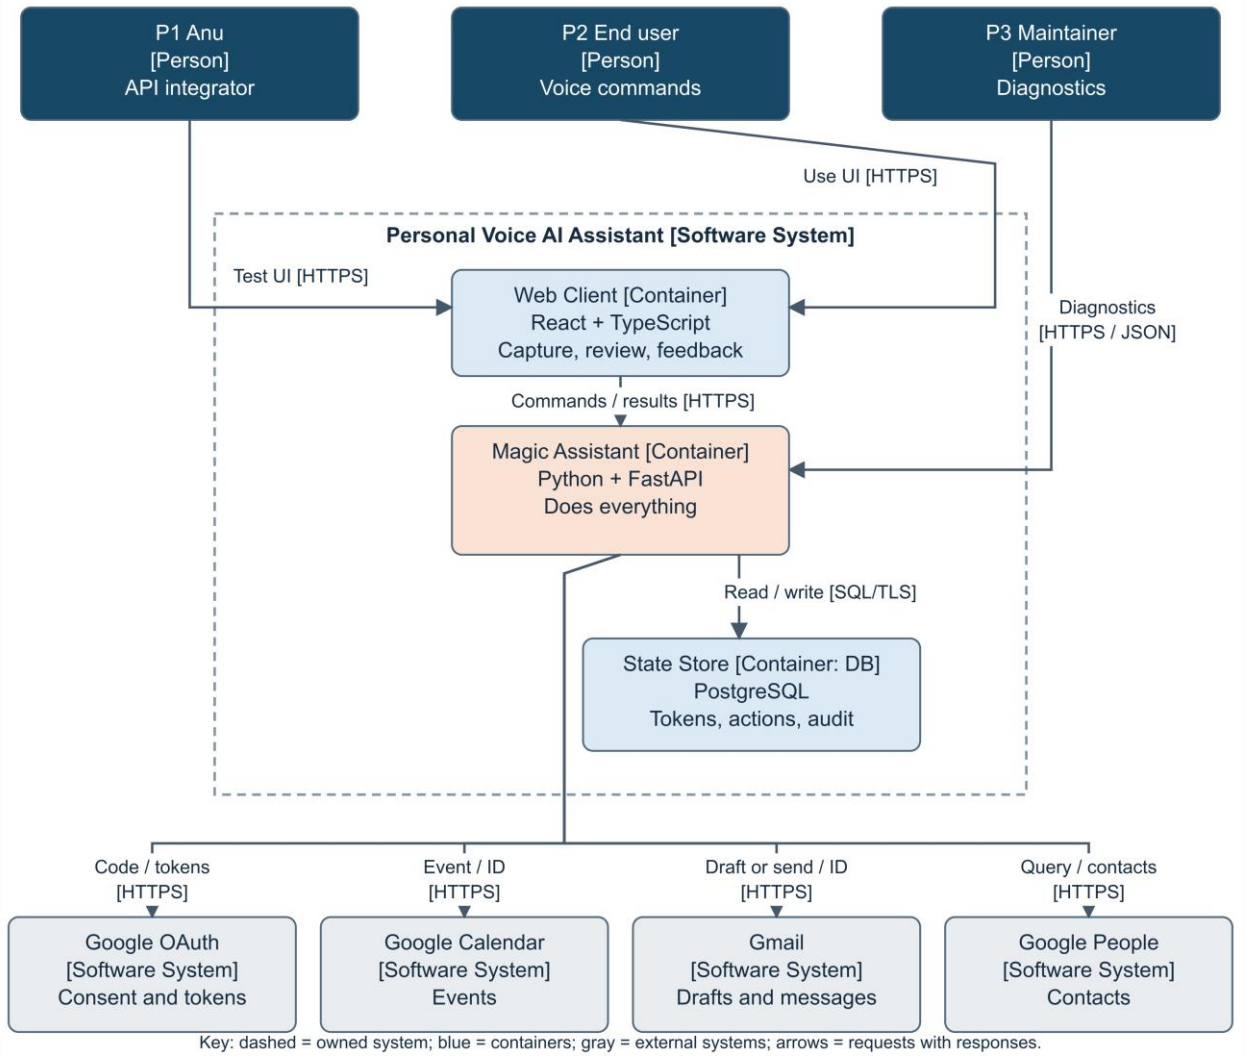
Баталгаажуулах болон OAuth consent нь хоёр тусдаа шат. Gmail draft нь өөрөө гаднын бичих үйлдэл тул ноорог хадгалахыг ил тод зөвшөөрүүлнэ; илгээх нь дахин тусдаа confirmation-тай. Сервер action ID, payload version/hash, user/session ба scope-ыг шалгана. UI товч идэвхгүй байхаас үл хамааран API нь баталгаагүй хүсэлтийг хориглоно.

Интерфейсийн гэрээ: POST /commands нь transcript, intent, action_id, payload_version, required_fields буцаана. POST /actions/{id}/confirm нь version-ыг батална. POST /actions/{id}/execute нь батлагдсан action-ыг гүйцэтгэнэ. Хариу бүр status, user_message, correlation_id-тай; provider token болон raw exception-ыг хэрэглэгчид буцаахгүй.

Consequences and validation

Давуу тал: буруу хаяг, цаг болон илүү эрх хүсэхийг хэрэглэгч анзаарна; Ану эрх дутуу, command буруу, provider алдааг ялгана. Сул тал: нэмэлт review алхамтай; speech/TTS ажиллахгүй үед текстийн үр дүн үлдэх ёстой. T-FR05/06/08/10/14, NFR-03, NFR-05-аар цуцлалт, version зөрүү, expired consent, keyboard focus-ыг шалгана.

UE 4 Container rework ба anti pattern



Анхны загвараас өөрчлөх зам

1. Цаасан sketch-ийн төлөвлөгөө: хэрэглэгч → UI → боловсруулалт → Google → үр дүн гэсэн урсгалыг эхэлж сонгосон. 2. Уншилтын эхлэл нь P2 хэрэглэгчийн команд. 3. Хайрцаг, суманд нэр ба өгөгдлийн шошго нэмэв. Энэ нь дасгалын загвар бөгөөд бодитоор цаасан sketch хийсэн нотолгоо биш.

“Does everything” нь OAuth, AI, Google API, audit-ын эзнийг нуусан. After зураг 2-т AI боловсруулалтыг B3 болгон салгаж, B2-т зөвшөөрөл ба интеграцийн хяналт үлдээв. B2-ын дотоод задлал зураг 3-т бий. Before 3 container → After 4 container; 8-аас хэтрээгүй. Өөрчлөлтийг дараах нэг хуудасны ADR-004 үндэслэнэ.

ADR 004 Magic Assistant задлах шийдвэр

Context and problem statement

Before зураг дахь Magic Assistant нь “Does everything” гэсэн тайлбартай. Дуу таних, intent, OAuth, Calendar/Gmail/People, логийг нэг эзэнгүй хайрцагт оруулснаар W1 Анугийн PP1–PP3 хүндрэл бүрт ямар модуль хариуцах нь харагдахгүй. AI-ийн удаашрал ба Google 403 алдааг нэг “assistant failed” хариугаар тайлбарлах эрсдэлтэй.

Decision drivers

FR-05/06/10 ба NFR-03-ын хяналтыг алгасахгүй байх; API алдааны эх үүсвэрийг тодорхойлох; C4-ийн container бүрийн нэр, технологи, хариуцлагыг ил болгох; хичээлийн хүрээнд deployment нэгжийг 8-аас бага байлгах.

Considered options

A. Хуучин хайрцгийн шошгыг л өөрчлөх: хамгийн бага ажилтай боловч хариуцлагын хил бодитой болохгүй. B. AI service-ийг тусгаарлаж, API дотор OAuth ба provider adapter-уудыг модульчлах: хариуцлага тодорхой, нэмэлт нэг deployment-тай. C. Google үйлчилгээ бүрийг microservice болгох: тусгаарлалт их боловч сүлжээ, transaction, monitoring-ийн зардал нэмэгдэнэ.

Decision

B хувилбарыг сонгов. B3 зөвхөн STT, intent, optional TTS гүйцэтгэнэ; Google credential болон tool execution эрх өгөхгүй. B2-ын B21 үр дүнг шалгаж, B22 нь scope ба confirmation-ыг баталсны дараа B23 provider API-г дуудна. B24 алдааг нэгдсэн хэлбэрт оруулж, B25 audit ба action state-г хадгална. B1, B4 үндсэн үүргээ хадгална.

Consequences

Эерэг: speech, consent, provider гэсэн алдааны хил ялгарна. Ану correlation ID-аар асуудлыг мөшгөж, AI модель солихдоо Google adapter-ыг өөрчлөхгүй. Сөрөг: AI service-ийн network timeout, versioned schema, health check шаардлагатай. Зөвхөн диаграмм салгасан нь код тусгаарлагдсаны баталгаа биш; модуль бүрийн тест хэрэгтэй.

Validation and follow up

W5-д AI timeout өгөхөд Google write 0, confirmation байхгүй үед write 0, 403 үед scope тайлбар, цуцлахад provider call 0 гэдгийг шалгана. T-FR02/03, T-FR05/06/10, T-NFR01–04-ийг дахин ажиллуулна. Before/After дахь actor ба external system-ийг ижил хадгалж, 14/15 FR mapping-ийг review хийнэ. Chinchilla х. 22–23-ын architecture/design сэдэв ба Bhatti х. 149-ийн зорилгоор үнэлэх чиглэлийг UE-4-т хэрэглэв.

Sprint хяналт ба эргэцүүлэл

Definition of Done

Шалгуур	Төлөв ба нотолгоо
arc42 1, 3, 5	Энэ баримтад бэлэн; гадаад workspace-д нийтлэх үлдсэн.
Context ба Container source	Хавсралтад PlantUML эх, зураг SVG vector орсон; repository commit үлдсэн.
3 MADR ба UE-4 ADR	001–003 болон refactoring 004 бэлэн; Proposed, багийн баталгаа хүлээнэ.
FR ≥ 80% mapping	14/15 = 93.3%; FR-15 orphan, W5 ажилтай.
3 actor ба W1 persona	3 actor холбогдсон; P2/P3-ын тусдаа persona card review үлдсэн.

Daily standup хариу

Өссөн arc42 хэсэг: 1, 3, 5 гэсэн гурван хэсэг. Диаграмм: харагдах SVG/PNG зурагтай, засварлах PlantUML эх хавсралтад бий. Тодруулах шийдвэр: ADR-001-ийн STT/intent model ба latency боломж; ADR-002-ын retention хугацааг review хийх. Эдгээр нь баримт бичгийн явцын хариу бөгөөд болсон багийн хурлын протокол биш.

Sprint retrospective

Хамгийн шууд үнэ цэнтэй хэсэг нь Section 5: requirement бүрийн эзэн болон FR-15-ын gap ил болсон. Санал болгож буй container түвшин нь 4 нэгж; баг зөвшөөрсөн гэх нотолгоо хараахан байхгүй. Дараагийн sprint-д ADR бүрт supersedes холбоос, review огноо, хэмжилтийн evidence link нэмнэ.

Гурван эргэцүүлэх асуултын хариу

1. Bhatti-ийн “Use labels” (х. 116) санаа энэ ажилд хамгийн хэрэгтэй байв. “AI engine” гэсэн ганц хайрцаг нь OAuth алдаа, permission, voice processing-ийг ялгахгүй. Шошгонд өгөгдөл, чиглэл, хариуцлагыг оруулахад Анугийн troubleshooting хэрэгцээг архитектуртай холбож чадсан.

2. Chinchilla-ийн navigation ба hierarchy (х. 47–51)-г W16-аас цааш хэрэглэнэ. Persona → requirement → building block → ADR гэсэн зам нь шинэ хөгжүүлэгчид шийдвэрийн шалтгааныг олоход тусална. Тиймээс Architecture индекс ба тогтвортой ID-уудыг хадгална.

3. Хамгийн том зөрүү нь диаграммын бүрэн байдал ба бодит нотолгооны хооронд байна. W3-т тестийн горим байсан ч гүйлт, peer review дутуу байсан. W4-т coverage 93.3% болсон нь тэр gap-ийг арилгаагүй. Дараагийн алхам нь peer review, persona validation, API contract болон latency/consent тестийн тайлан юм.

Architecture байршуулалт

Architecture workspace бүтэц

Architecture/index → arc42/01-goals, arc42/03-context, arc42/05-building-blocks, diagrams/context.puml, diagrams/container-after.puml, diagrams/container-before.puml, adr/001-tech-stack, adr/002-persistence, adr/003-interface, adr/004-refactoring. Энэ нь нийтлэх бүтэц; repository эсвэл Confluence-д нийтлэгдсэн гэсэн баталгаа биш.

Хавсралтын эхийг UTF-8 .puml файлд хадгалж C4-PlantUML-ээр SVG болгон render хийнэ. Word доторх зургууд SVG vector эх ба PNG compatibility preview-тэй. PlantUML эх нь бүтэц засах үндсэн хэлбэр; дүрслэлийн байрлал render engine-ээс шалтгаалж өөрчлөгдөж болно. C4 library-г repo-д version-тэй хадгалах нь давтагдах build-д тохиромжтой.

W5 тэргүүлэх ажлууд

FR-15-ын history эзнийг тодорхойлох; P2/P3 persona card батлах; STT/intent model benchmark; OAuth scope ба retry contract шалгах; ADR review хийх; диаграммын source болон ADR-ийг repository/workspace-д байршуулж холбоосыг индексэд нэмэх.

context diagram кодоор

context.puml C4-PlantUML standard library

```
@startuml
!include <C4/C4_Context>
title Personal Voice AI Assistant - System Context
Person(anu, "P1 Anu", "API integrator")
Person(user, "P2 End user", "Voice commands")
Person(ops, "P3 Maintainer", "Diagnostics")
System_Ext(oauth, "Google OAuth", "Consent and tokens")
System_Ext(cal, "Google Calendar", "Events")
System_Ext(mail, "Gmail", "Drafts and messages")
System_Ext(people, "Google People", "Contacts")
System(app, "Personal Voice AI Assistant", "Voice commands and reviewed Google actions")
Rel(anu, app, "Configure and test")
Rel(user, app, "Speak, review, confirm; receive results")
Rel(ops, app, "Inspect redacted diagnostics")
Rel(app, oauth, "Consent request / tokens")
Rel(app, cal, "Event data / event ID")
Rel(app, mail, "Draft or send / resource ID")
Rel(app, people, "Name query / contacts")
SHOW_LEGEND()
@enduml
```

Засварлахдаа actor болон system ID-уудыг тогтвортой хадгална. API сүманд хүсэлт / хариу гэсэн өгөгдөл бичсэн; internal container болон external system-ийг boundary-гаар ялгасан.

container-after diagram кодоор

container-after.puml C4-PlantUML standard library

```
@startuml
!include <C4/C4_Container>
title Personal Voice AI Assistant - After
Person(anu, "P1 Anu", "API integrator")
Person(user, "P2 End user", "Voice commands")
Person(ops, "P3 Maintainer", "Diagnostics")
System_Ext(oauth, "Google OAuth", "Consent and tokens")
System_Ext(cal, "Google Calendar", "Events")
System_Ext(mail, "Gmail", "Drafts and messages")
System_Ext(people, "Google People", "Contacts")
System_Boundary(s, "Personal Voice AI Assistant") {
  Container(web, "Web Client", "React + TypeScript", "Capture, review, feedback")
  Container(api, "Assistant API", "Python + FastAPI",
    "Consent, validation, Google tools")
  Container(ai, "AI Service", "Python + FastAPI", "STT, intent, optional TTS")
  ContainerDb(db, "State Store", "PostgreSQL", "Tokens, actions, audit")
}
Rel(anu, web, "Test UI", "HTTPS")
Rel(user, web, "Use UI", "HTTPS")
Rel(ops, api, "Inspect redacted diagnostics", "HTTPS/JSON")
Rel(web, api, "Commands, confirmations / results", "HTTPS/JSON")
Rel(api, ai, "Audio, text / transcript, intent, audio", "HTTP/JSON")
Rel(api, db, "Read and write state", "SQL/TLS")
Rel(api, oauth, "Code and consent / tokens", "HTTPS")
Rel(api, cal, "Event data / event ID", "HTTPS/JSON")
Rel(api, mail, "Draft or send / resource ID", "HTTPS")
Rel(api, people, "Name query / contacts", "HTTPS/JSON")
SHOW_LEGEND()
@enduml
```

Засварлахдаа actor болон system ID-уудыг тогтвортой хадгална. API сумand хүсэлт / хариу гэсэн өгөгдөл бичсэн; internal container болон external system-ийг boundary-гаар ялгасан.

container-before diagram кодоор

container-before.puml C4-PlantUML standard library

```
@startuml
!include <C4/C4_Container>
title Personal Voice AI Assistant - Before
Person(anu, "P1 Anu", "API integrator")
Person(user, "P2 End user", "Voice commands")
Person(ops, "P3 Maintainer", "Diagnostics")
System_Ext(oauth, "Google OAuth", "Consent and tokens")
System_Ext(cal, "Google Calendar", "Events")
System_Ext(mail, "Gmail", "Drafts and messages")
System_Ext(people, "Google People", "Contacts")
System_Boundary(s, "Personal Voice AI Assistant") {
  Container(web, "Web Client", "React + TypeScript", "Capture, review, feedback")
  Container(api, "Magic Assistant", "Python + FastAPI",
    "Does everything")
  ContainerDb(db, "State Store", "PostgreSQL", "Tokens, actions, audit")
}
Rel(anu, web, "Test UI", "HTTPS")
Rel(user, web, "Use UI", "HTTPS")
Rel(ops, api, "Inspect redacted diagnostics", "HTTPS/JSON")
Rel(web, api, "Commands, confirmations / results", "HTTPS/JSON")
Rel(api, db, "Read and write state", "SQL/TLS")
Rel(api, oauth, "Code and consent / tokens", "HTTPS")
Rel(api, cal, "Event data / event ID", "HTTPS/JSON")
Rel(api, mail, "Draft or send / resource ID", "HTTPS")
Rel(api, people, "Name query / contacts", "HTTPS/JSON")
SHOW_LEGEND()
@enduml
```

Засварлахдаа actor болон system ID-уудыг тогтвортой хадгална. API суманд хүсэлт / хариу гэсэн өгөгдөл бичсэн; internal container болон external system-ийг boundary-гаар ялгасан.